



Факультет Программной Инженерии и Компьютерной техники

Исследование протоколов, форматов обмена информацией и языков
разметки документов

Лабораторная работа №4

Вариант 85

Выполнил: Малых Кирилл Романович

Группа: P3132

Преподаватель: Бострикова Дарья Константиновна

Санкт-Петербург, 2025г.

Содержание

1. Порядок выполнения работы	3
2. Выполнение задачи	6
Обязательное задание:	6
Дополнительное задание №1:	6
Дополнительное задание №2:	7
Дополнительное задание №3:	7
Дополнительное задание №4	8
3. Заключение	9
4. Список использованной литературы.....	10

1. Порядок выполнения работы

1. Определить номер варианта как остаток деления на 132 своего идентификационного номера в ISU: например, $125598 / 132 = 16$. В случае, если в обоих указанных днях недели нет занятий, то увеличить номер варианта на восемь. В случае, если занятий нет и в новом наборе дней, то продолжать увеличивать на восемь.

2. Изучить форму Бэкуса-Наура.

3. Изучить основные принципы организации формальных грамматик.

4. Изучить особенности языков разметки/форматов JSON, RON, HCL, YAML, TOML, INI, XML.

5. Понять устройство страницы с расписанием на примере расписания лектора: https://itmo.ru/ru/schedule/3/125598/raspisanie_zanyatiy.htm

6. Исходя из структуры расписания конкретного дня, сформировать файл с расписанием в формате, указанном в задании в качестве исходного. При этом необходимо, чтобы хотя бы в одной из выбранных дней было не менее двух занятий (можно использовать своё персональное). В случае, если в данный день недели нет таких занятий, то увеличить номер варианта ещё на восемь.

7. **Обязательное задание** (позволяет набрать до 50 процентов от максимального числа баллов БаРС за данную лабораторную). Написать программу на языке Python 3.x или любом другом, которая:

- осуществляет парсинг и конвертацию исходного файла в бинарный объект (=десериализацию);
- для решения задачи использует формальные грамматики; то есть ваш код должен уметь осуществлять парсинг и конвертацию любых данных, представленных в исходном формате, в данные, представленные в результирующем формате (как с готовыми библиотеками из дополнительного задания №2);
- не использует готовые библиотеки, в том числе регулярные выражения в Python и библиотеки для загрузки файлов.

8. *Дополнительное задание №1* (позволяет набрать +15 процентов от максимального числа баллов БаРС за данную лабораторную). Написать программу на языке Python 3.x или любом другом, которая:

- осуществляет парсинг и конвертацию бинарного объекта,

полученного в обязательном задании, в новый формат (=сериализацию);

- для решения задачи использует формальные грамматики;
- не использует готовые библиотеки, в том числе регулярные

выражения в Python и библиотеки для загрузки файлов.

9. *Дополнительное задание №2* (позволяет набрать +10 процентов от максимального числа баллов БаРС за данную лабораторную).

а) Найти готовые библиотеки, осуществляющие аналогичный парсинг и конвертацию файлов (десериализацию и сериализацию).

б) Переписать исходный код и код из дополнительного задания №1, применив найденные библиотеки. Регулярные выражения также нельзя использовать.

с) Сравнить полученные результаты и объяснить их сходство/различие. Объяснение должно быть отражено в отчёте.

10. *Дополнительное задание №3* (позволяет набрать +20 процентов от максимального числа баллов БаРС за данную лабораторную). Переписать код из дополнительного задания №1, чтобы сериализация происходила в XML файл.

11. *Дополнительное задание №4* (позволяет набрать +5 процентов от максимального числа баллов БаРС за данную лабораторную).

а) Используя свою исходную программу из обязательного задания и программы из дополнительных заданий, сравнить стократное время выполнения парсинга + конвертации в цикле.

b) Проанализировать полученные результаты и объяснить их сходство/различие. Объяснение должно быть отражено в отчёте.

12. Проверить, что все пункты задания выполнены и выполнены верно.

13. Написать отчёт о проделанной работе.

14. Подготовиться к устным вопросам на защите.

2. Выполнение задачи

Обязательное задание:

Исходный/входной INI-файл:

<https://github.com/tetraminomusic/ITMO/blob/main/Информатика/Лабораторные%20работы/ЛБ4/input.ini>

Исходный код программы:

<https://github.com/tetraminomusic/ITMO/tree/main/Информатика/Лабораторные%20работы/ЛБ4/Обязательное%20задание>

Получившейся бинарный объект:

<https://github.com/tetraminomusic/ITMO/blob/main/Информатика/Лабораторные%20работы/ЛБ4/dict.txt>

Дополнительное задание №1:

Входной бинарный объект:

<https://github.com/tetraminomusic/ITMO/blob/main/Информатика/Лабораторные%20работы/ЛБ4/dict.txt>

Исходный код программы:

<https://github.com/tetraminomusic/ITMO/tree/main/Информатика/Лабораторные%20работы/ЛБ4/Доп1>

Выходной RON-файл:

<https://github.com/tetraminomusic/ITMO/blob/main/Информатика/Лабораторные%20работы/ЛБ4/output.ron>

Дополнительное задание №2:

Исходные переписанные коды с библиотеками:

<https://github.com/tetraminomusic/ITMO/tree/main/Информатика/Лабораторные%20работы/ЛБ4/Дон2>

Использованные готовые библиотеки: стандартная библиотека Python json для парсинга json, configparser для деструктуризации файла-конфигурации INI и последующего преобразования в удобный словарь.

Файл результата в целом не имеет отличий, единственный момент здесь кроется в отступах: мною написанный парсер делает полноценный табуляции для секции и содержимого секций, в то время как подключенные модули используют отдельный пробел. С подключенными библиотеками код стал более читаемым и сократился практически в 2 раза.

Дополнительное задание №3:

Входной бинарный объект:

<https://github.com/tetraminomusic/ITMO/blob/main/Информатика/Лабораторные%20работы/ЛБ4/dict.txt>

Исходный код программы:

<https://github.com/tetraminomusic/ITMO/tree/main/Информатика/Лабораторные%20работы/ЛБ4/Дон3>

Выходной XML-файл:

<https://github.com/tetraminomusic/ITMO/blob/main/Информатика/Лабораторные%20работы/ЛБ4/output.xml>

Дополнительное задание №4

Исходный код программы-бенчмарка:

<https://github.com/tetraminomusic/ITMO/tree/main/Информатика/Лабораторные%20работы/ЛБ4/Don4>

Результат работы данной программы:

https://github.com/tetraminomusic/ITMO/blob/main/Информатика/Лабораторные%20работы/ЛБ4/Don4/Output_results

В результате проверки скорости 100-кратной работы парсеров заметим, что написанный без библиотек парсер работает быстрее, чем с библиотеками. Кастомный парсер оказался быстрее библиотечного благодаря специализации под конкретный формат данных и отсутствию избыточных проверок. ConfigParser проигрывает в скорости из-за универсальности и сложных внутренних преобразований, но обеспечивает надежную работу с любыми INI-файлами. Для учебных данных оптимальна кастомная реализация, для продакшена — библиотечное решение.

3. Заключение

В ходе данной работы я узнал много нового про разметку документов, впервые познакомился с таким понятием, как “парсинг”, поближе познакомился с формальными грамматиками, а также научился проводить бенчмарк программ на Python. Немало важно хочу отметить, что я обучился основам библиотек, связанных с написанием парсеров и лексеров файлов, например, json и configparser.

4. Список использованной литературы

1) Грошев А.С. Г89 Информатика: Учебник для вузов / А.С. Грошев. – Архангельск, Арханг. гос. техн. ун-т, 2010. – 470с.

URL: <https://narfu.ru/university/library/books/0690.pdf>

2) Балакшин П.В., Соснин В.В., Машина Е.А. Информатика. – СПб: Университет ИТМО, 2020. – 122 с.

3) Doctor_IT – Основы парсинга на Python: от Requests до Selenium

URL: <https://habr.com/ru/companies/selectel/articles/754674/>